8

BIBLIOTECAS PARA APRENDIZAJE POR REFUERZO

¿QUÉ BIBLIOTECAS MÁS RELEVANTES EXISTEN PARA RL?

Agentes

AgileRL

CleanRL

RLlib

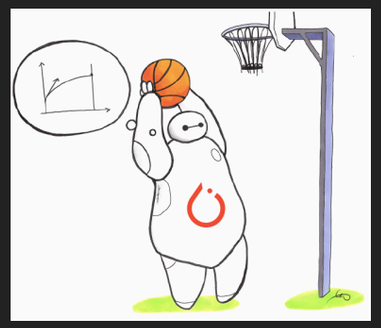

Entornos

MiniHack

PettingZoo

MuJoCo

Gymnasium

MINIHACK

- Propósito: Crear entornos de RL basados en el juego NetHack, un roguelike complejo.
- Uso principal: Investigación académica en entornos desafiantes y con exploración profunda.
- Características clave:
  - ✓ Basado en NetHack Learning Environment (NLE).
  - ✓ Requiere razonamiento complejo, memoria y planificación.
  - ✓ Muy útil para probar agentes en tareas similares a juegos de texto o juegos de aventuras.
- Es una colección de implementaciones minimalistas de algoritmos de RL.
- Cada archivo .py es autocontenible (solo unas ~200 líneas).

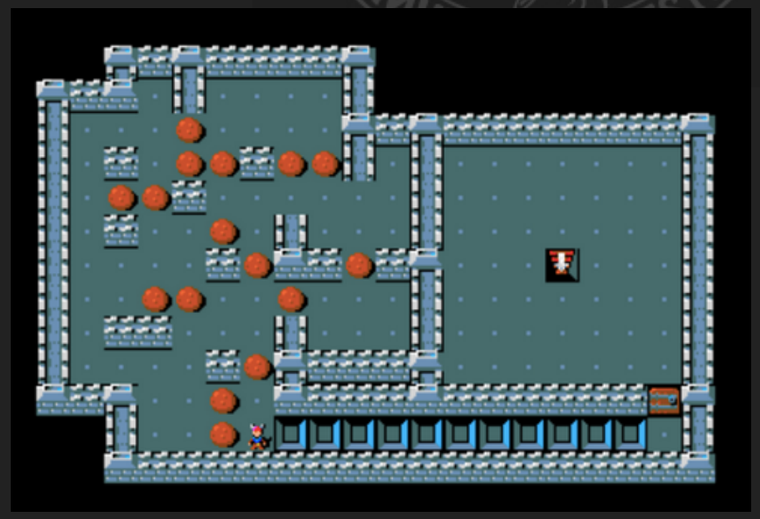

PETTINGZOO

- Propósito: Proporcionar entornos para Multi-Agent Reinforcement Learning (MARL).
- Uso principal: Investigación y entrenamiento en escenarios con múltiples agentes.
- Características clave:
  - ✓ API estándar similar a Gym pero adaptada a multi-agente.
  - ✓ Compatible con Stable-Baselines, RLlib, y otros frameworks.
  - ✓ Soporta entornos paralelos y secuenciales.

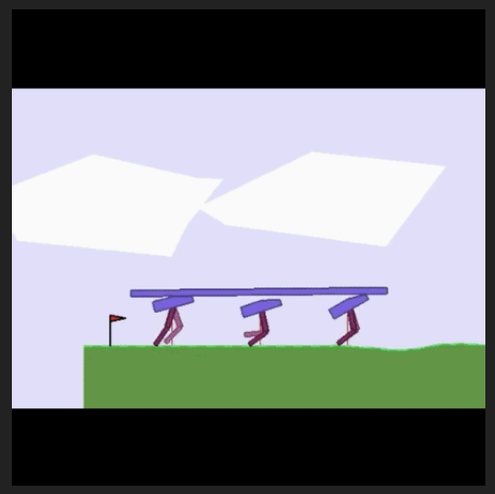

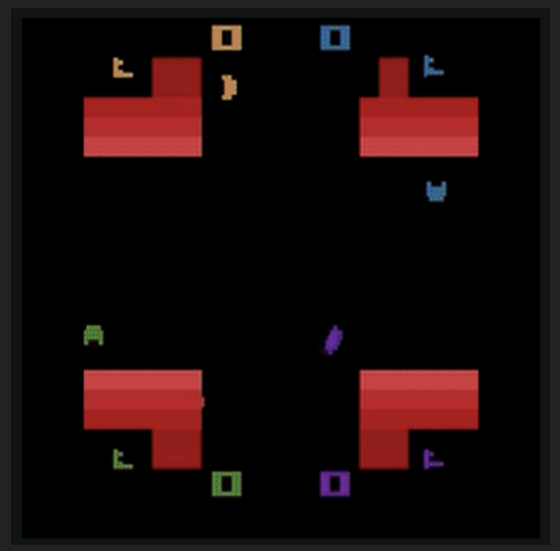

MUJOCO

MuJoCo

- Propósito: Simulación física de robots y cuerpos rígidos.
- Uso principal: Aprendizaje de control en robótica.
- Características clave:
  - ✓ Precisión física muy alta.
  - ✓ Usado como backend en varios entornos de control como los de Gym.
  - ✓ Propiedad de DeepMind (Google).

GYMNASIUM

Gymnasium

- Propósito: Crear y usar entornos de RL estandarizados.
- Uso principal: Entrenamiento y prueba de algoritmos de RL.
- Características clave:
  - ✓ Es el sucesor de OpenAI Gym, mantenido por Farama Foundation.
  - ✓ Interfaz simple y unificada.
  - ✓ Compatible con otras bibliotecas como Stable-Baselines y CleanRL.

COMO USAR GYMNASIUM?

Gymnasium

- Gymnasium se implementa mediante una API entre el agente y el entorno.

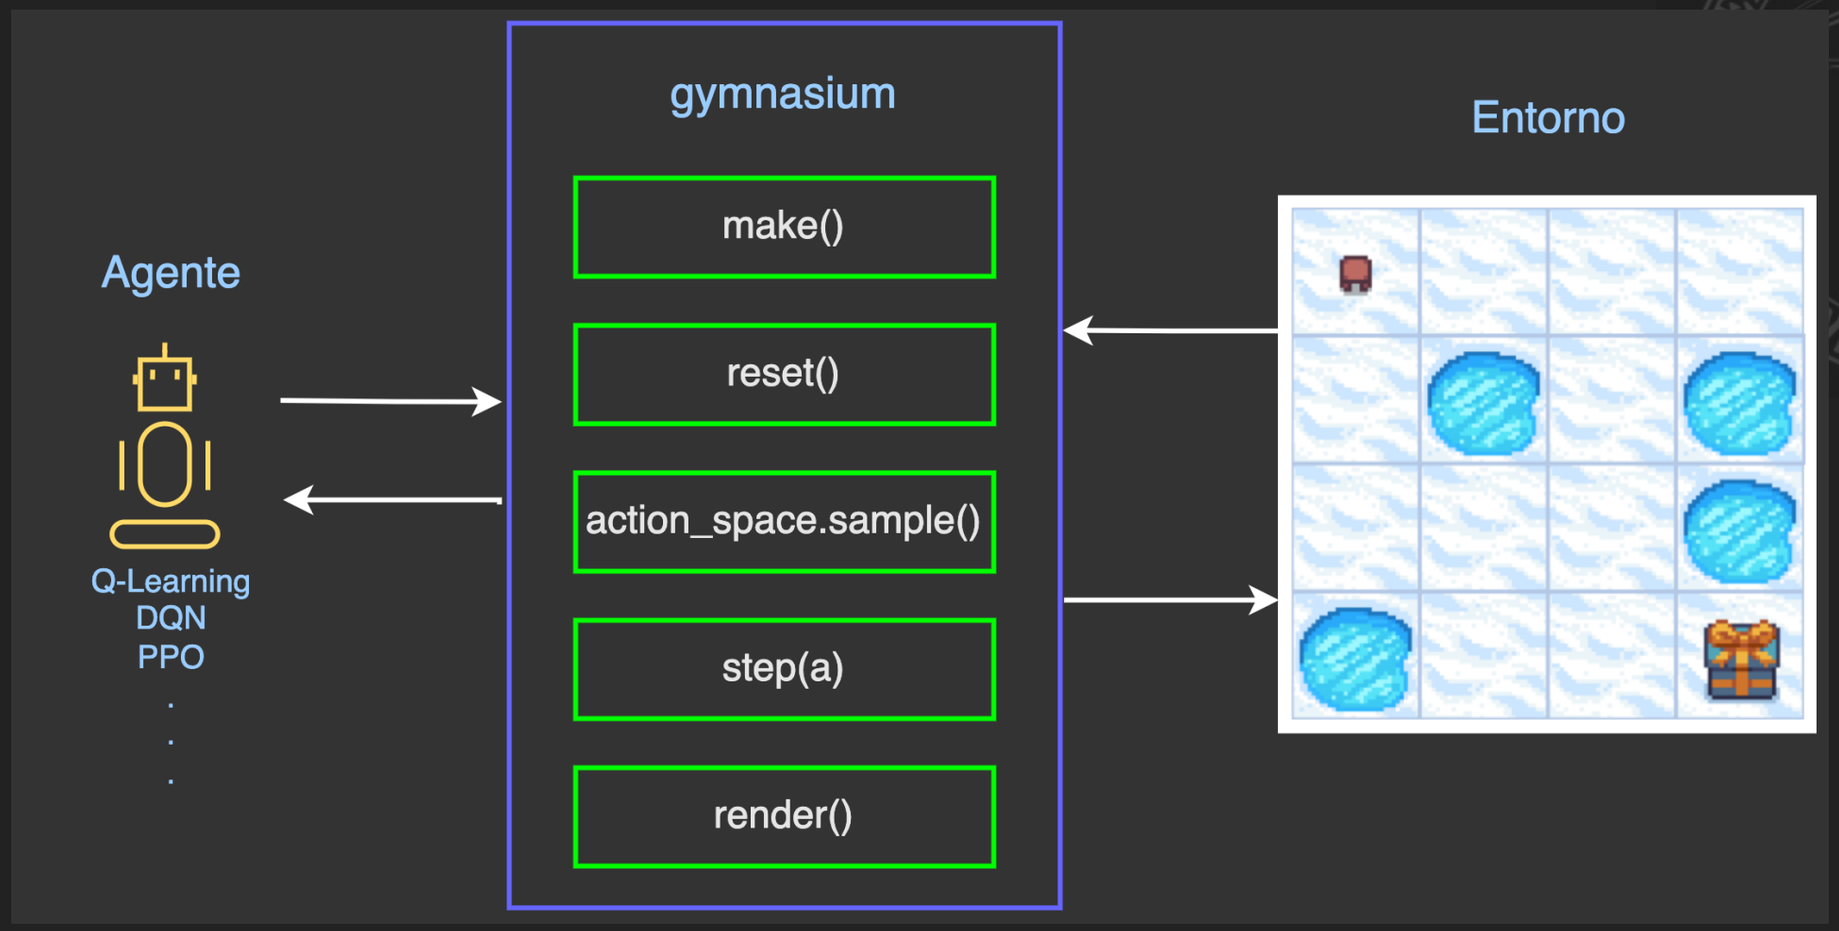

COMO USAR GYMNASIUM?

Gymnasium

- make() crea el entorno (una instancia).
- reset() establece al estado inicial al agente en cada episodio y devuelve s_0.
- action_space.sample() selecciona en forma aleatoria una acción posible desde el estado que el agente observa.
- step(a) ejecuta la acción que seleccionó y devuelve el nuevo estado y la recompensa.
- render() grafica el entorno.

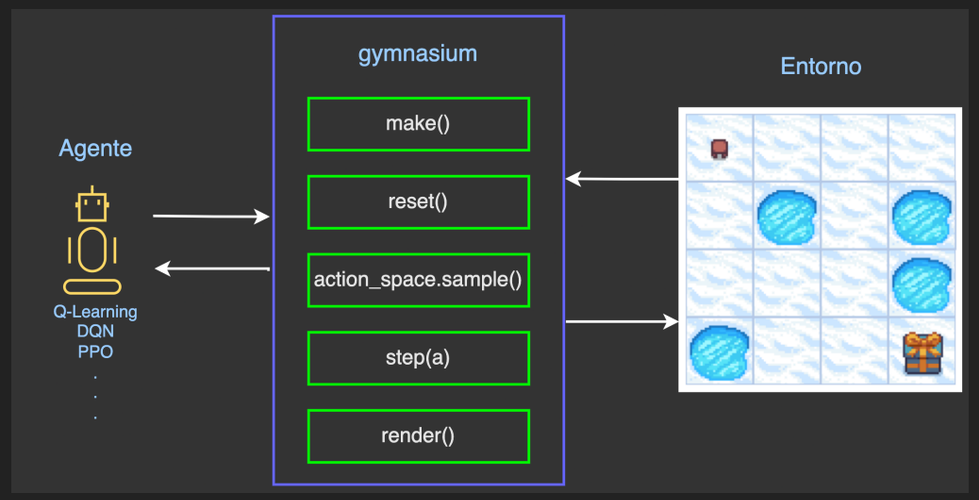

COMO USAR GYMNASIUM?

Gymnasium

```
import gymnasium as gym
import matplotlib.pyplot as plt
env = gym.make("FrozenLake-v1", render_mode="rgb_array") # Crear el entorno "FrozenLake-v1"
obs, info = env.reset() # Reiniciar el entorno
done = False
final_frame = None  # Almacenar el último frame para renderizar al final
while not done:
    action = env.action_space.sample()  # Seleccionar acción aleatoria
    obs, reward, done, truncated, info = env.step(action)  # Ejecutar la acción
    final_frame = env.render()  # Renderizar el entorno y almacenar el frame actual
plt.imshow(final_frame) # Mostrar el último frame al final del episodio
plt.axis("off")
plt.show()
env.close() # Cerrar el entorno al finalizar
```

COMO USAR GYMNASIUM?

Gymnasium

```
import gymnasium as gym
import matplotlib.pyplot as plt
env = gym.make("FrozenLake-v1", render_mode="rgb_array") # Cargar el entorno "FrozenLake-v1"
obs, info = env.reset() # Reiniciar el entorno
done = False
final_frame = None  # Almacenar el último frame para renderizar al final
while not done:
    action = env.action_space.sample()  # Seleccionar acción aleatoria
    obs, reward, done, truncated, info = env.step(action)  # Ejecutar la acción
    final_frame = env.render()  # Renderizar el entorno y almacenar el frame actual
    print(f"Estado: {obs}, Recompensa: {reward}, Finalizado: {done}, Truncado: {truncated}")
plt.imshow(final_frame) # Mostrar el último frame al final del episodio
plt.axis("off")
plt.show()
env.close() # Cerrar el entorno al finalizar
```

EJEMPLO

Gymnasium

```
Estado: 0, Recompensa: 0.0, Finalizado: False, Truncado: False
Estado: 1, Recompensa: 0.0, Finalizado: False, Truncado: False
Estado: 5, Recompensa: 0.0, Finalizado: True, Truncado: False
```

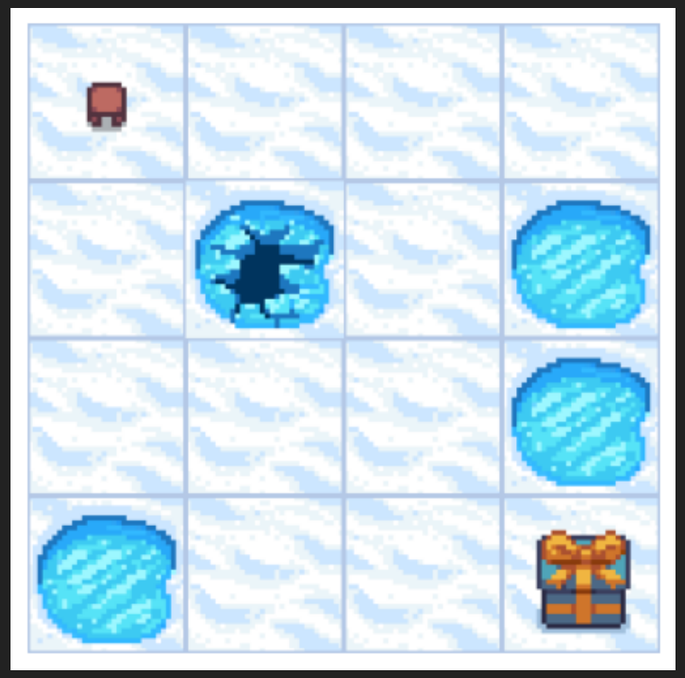

IMPLEMENTACIÓN CON Q-LEARNING

Gymnasium

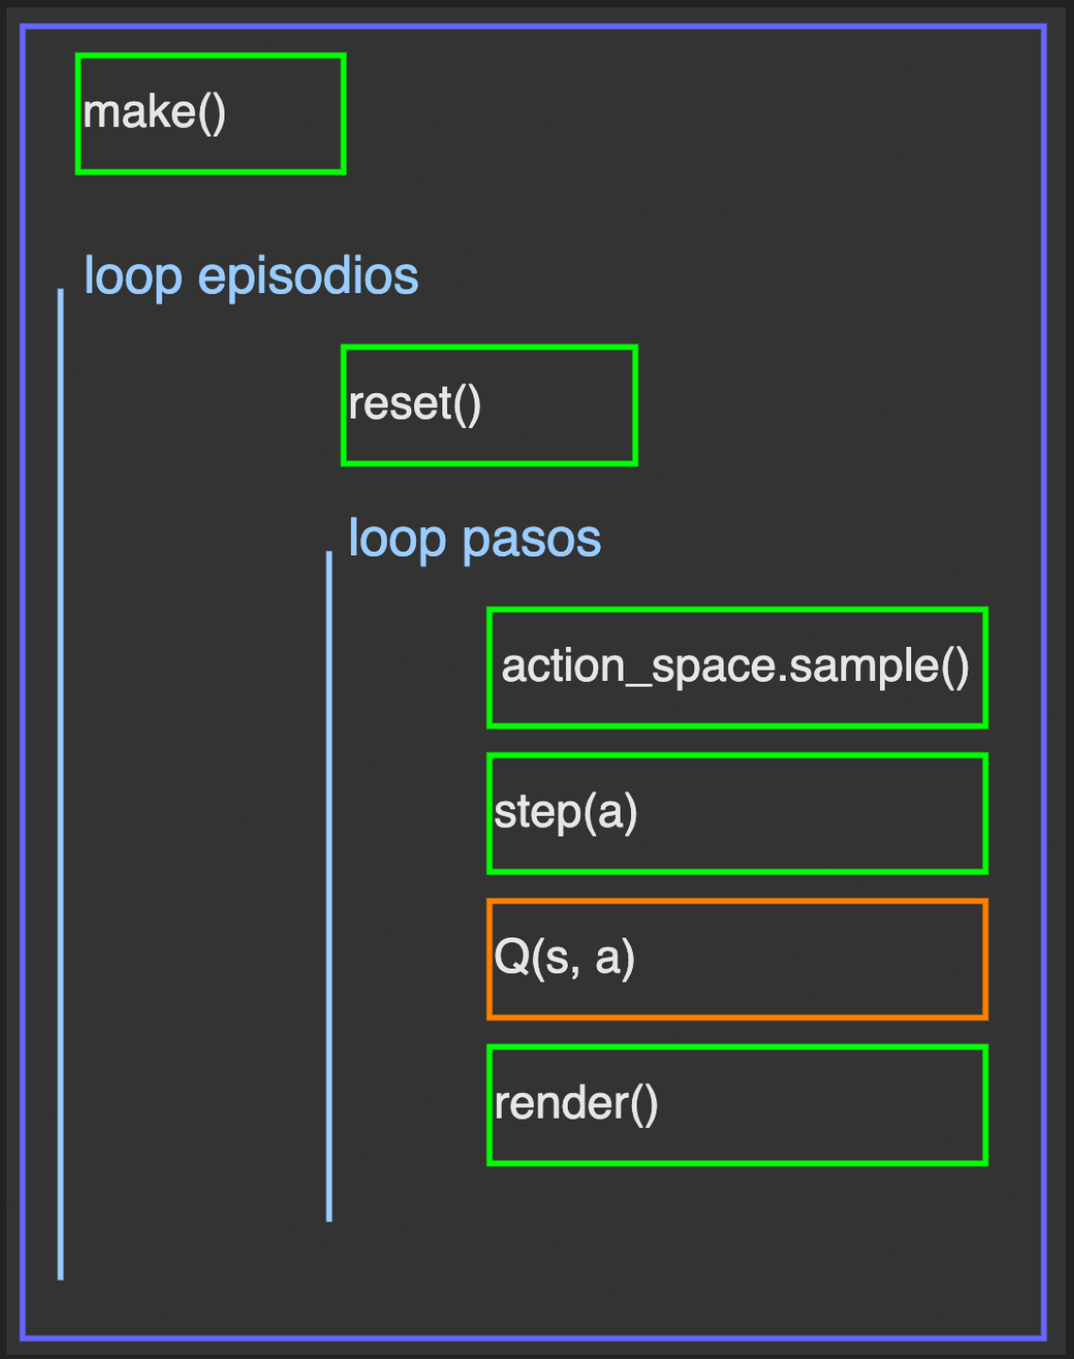

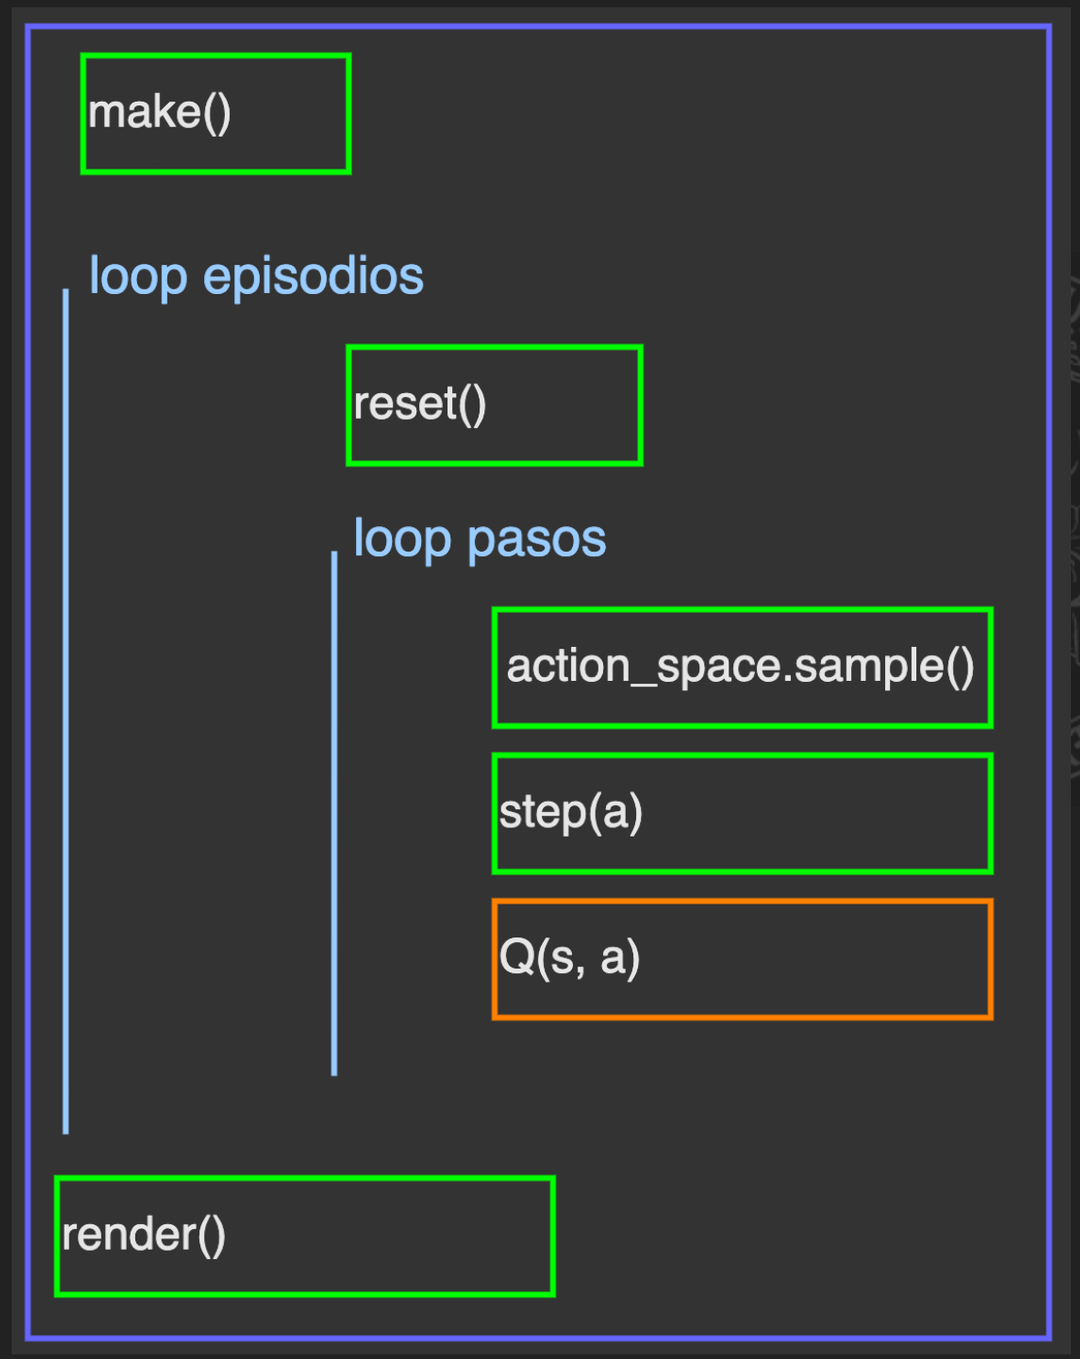

¿SE PUEDEN MODIFICAR LAS RECOMPENSAS?

- Si. Existen 2 formas:
  - ✓ Directa (externa)
  - ✓ Wrapper

¿SE PUEDEN MODIFICAR LAS RECOMPENSAS?

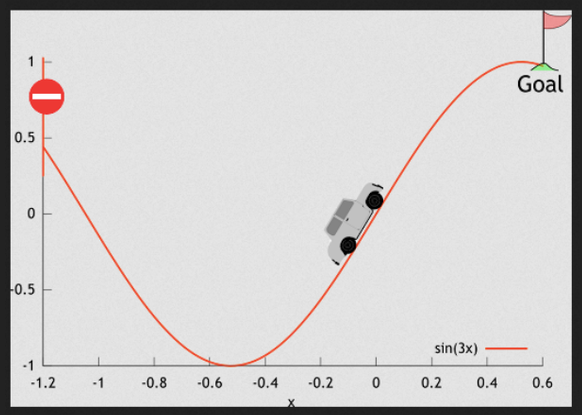

- Directa:
- No se se puede cambiar la recompensa interna del entorno (está hardcodeada en Gymnasium).
- Pero, si es posible redefinir la recompensa después de recibirla en el bucle de entrenamiento. Por ejemplo:

```
nuevo_estado, recompensa, done, _, _ = env.step(accion)
# Sobrescribir la recompensa:
if nuevo_estado[0] >= 0.5:  # Si alcanza la meta
    recompensa = 100  # Premio grande
elif accion == 2 and nuevo_estado[1] > 0:  # Reforzar acelerar hacia arriba
    recompensa = 0.1  # Pequeño incentivo
```

- Esto no afecta al entorno, pero sí a cómo el agente aprende de sus acciones.
- La recompensa original es fija, pero se puede transformarla para mejorar el aprendizaje.

¿SE PUEDEN MODIFICAR LAS RECOMPENSAS?

- Wrapper:
- Consiste en crear una subclase que modifique las recompensas de manera estructurada:
  - ✓ esto hace el código más mantenible y escalable.
  - ✓ es la forma más limpia y profesional de manejar recompensas customizadas.

```python
from gymnasium.wrappers import RewardWrapper

class CustomRewardWrapper(RewardWrapper):
    def step(self, action):
        observation, reward, terminated, truncated, info = self.env.step(action)
        if observation[0] >= 0.5:
            reward = 100  # Recompensa por éxito
        elif action == 2 and observation[1] > 0:  # Acelerar cuando sube
            reward = 0.1
        return observation, reward, terminated, truncated, info

# Usarlo al crear el entorno:
env = gym.make("MountainCar-v0")
env = CustomRewardWrapper(env)
```

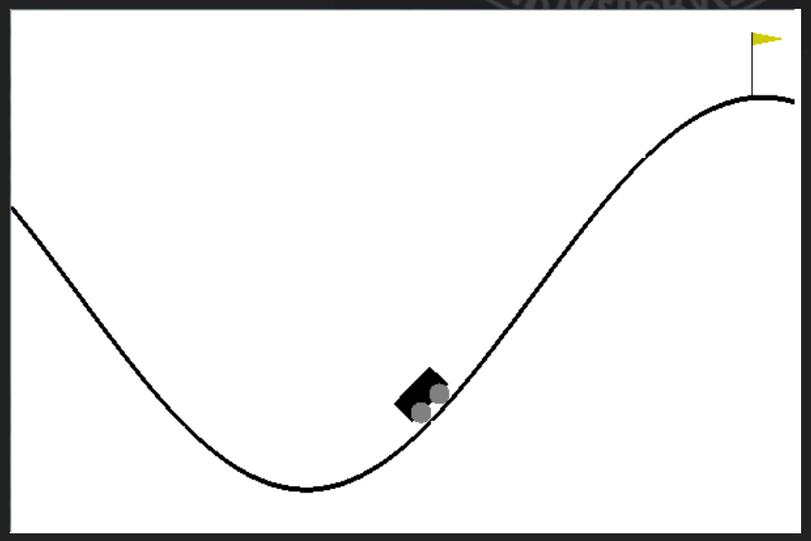

¿SE PUEDEN MODIFICAR LAS RECOMPENSAS?

- Un wrapper es una clase que envuelve un entorno de Gymnasium para modificarlo sin alterar su código original.
- Funciona como una "capa intermedia" que intercepta las interacciones con el entorno (como step(), reset()) y permite:
  - ✓ Modificar recompensas.
  - ✓ Cambiar observaciones (estados).
  - ✓ Añadir condiciones de terminación personalizadas.
  - ✓ Limitar acciones o estados.
- Es una técnica poderosa para adaptar entornos estándar a necesidades específicas, manteniendo la compatibilidad con la API de Gymnasium.

ENTORNOS CLÁSICOS DE GYMNASIUM

- LunarLander-v2
- BipedalWalker-v3
- CarRacing-v2
- CartPole-v1
- Acrobot-v1
- Pendulum-v1
- HalfCheetah-v4
- Hopper-v4
- Walker2d-v4
- Ant-v4
- Humanoid-v4
- FrozenLake-v1
- Taxi-v3
- CliffWalking-v0

AGILERL

- Propósito: Entrenamiento de algoritmos de RL con aprendizaje activo y evolución adaptativa.
- Uso principal: AutoRL (optimización automática de agentes).
- Características clave:
  - ✓ Selección automática de modelos y arquitecturas.
  - ✓ Evaluación continua del desempeño.
  - ✓ Bueno para experimentación con diferentes estrategias.
- Optimización de hiperparámetros (HPO) evolutiva (basada en algoritmos genéticos) que que reduce los tiempos de entrenamiento..
- Agentes que provee: DQN, PPO, A2C, SAC, TD3, DDPG, MADDPG, MATD3, IPPO.

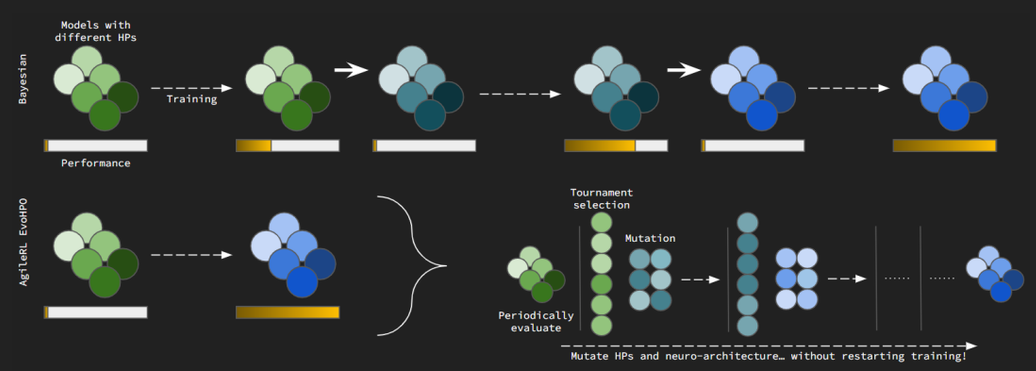

CLEANRL

CleanRL

- Propósito: Proveer implementaciones limpias y mínimas de algoritmos de RL.
- Uso principal: Estudio, enseñanza y depuración de algoritmos de RL.
- Características clave:
  - ✓ Código corto y claro, ideal para aprender.
  - ✓ Basado en PyTorch.
  - ✓ Cada script suele ser autocontenible (1 archivo .py por algoritmo).
- Agentes que provee: DQN, C51, PPO, SAC, TD3, DDPG, PPG.

RLIB

- Propósito: Entrenamiento escalable de RL distribuido y producción (cluster).
- Uso principal: Aplicaciones de RL a gran escala.
- Características clave:
  - ✓ Esta basada en Ray (el motor que permite computación distribuida).
  - ✓ Tolera entrenamiento paralelo y multinodo.
  - ✓ Ray incluye Tune (ajuste de hiperparámetros) y Serve (despliegue de modelos).
- Agentes que provee: DQN, A3C, PPO, SAC, TD3, DDPG, IMPALA, APEX.
- Puede trabajar con muñtiples agentes.

STABLE BASELINE 3

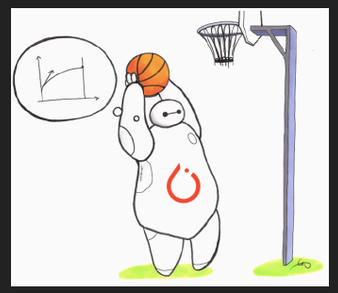

- Propósito: Implementaciones robustas y listas para usar de algoritmos de RL.
- Uso principal: Entrenamiento rápido y reproducible de agentes RL.
- Características clave:
  - ✓ Basado en PyTorch.
  - ✓ Fácil de usar con model.learn() y model.predict().
  - ✓ Excelente para prototipado rápido y experimentos controlados.
- Agentes que provee: DQN, A2C, PPO, HER, SAC, TD3, DDPG.
- Soporta también acciones continuas y discretas y multiprocesamiento.

STABLE BASELINE 3 – EJEMPLO SIMPLE

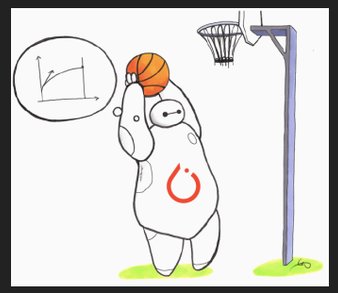

```
import gymnasium as gym
from stable_baselines3 import DQN
env = gym.make("MountainCar-v0", render_mode=None) # Crea el entorno
model = DQN("MlpPolicy", env, verbose=1) # Crea el modelo DQN (0 silencio, 1 c/ ciertos pasos, 2 todo)
model.learn(total_timesteps=10_000) # Entrena el modelo por 10,000 pasos
# evaluacion del agente (sin entrenar más)
obs, _ = env.reset()
done = False
while not done:
    action, _states = model.predict(obs)
    obs, reward, done, truncated, info = env.step(action)
    env.render()
env.close()
```

REFERENCIAS BIBLIOGRÁFICAS Y WEB (I)

- https://stable-baselines3.readthedocs.io/en/master/
- https://docs.cleanrl.dev/
- https://docs.agilerl.com/en/latest/
- https://docs.ray.io/en/latest/rllib/index.html
- https://gymnasium.farama.org/
- https://github.com/Farama-Foundation/PettingZoo
- https://github.com/google-deepmind/mujoco
- https://minihack.readthedocs.io/en/latest/
- "Comparison of reinforcement learning algorithms applied to Humanoid-v2 in MuJoCo using CleanRL" https://www.youtube.com/watch?v=n0Cpqzqzroo